

**DETEKSI ANOMALI PERILAKU PEMBELIAN LPG 3 KG DI
PANGKALAN BERLIAN MENGGUNAKAN ARTIFICIAL
NEURAL NETWORK**



Oleh:

Muhammad Rizki Ramadhan

NIM. 2310817310008

Naila Hanifah

NIM. 2310817220016

**PROGRAM STUDI TEKNOLOGI INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS LAMBUNG MANGKURAT
2026**

DAFTAR ISI

DAFTAR GAMBAR	iii
DAFTAR TABEL	iv
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan	2
1.4 Manfaat	2
BAB II TINJAUAN PUSTAKA.....	3
2.1 LPG 3 Kg Bersubsidi dan Permasalahan Distribusinya.....	3
2.2 Deteksi Anomali dengan Machine Learning.....	3
2.3 Artificial Neural Network (ANN).....	4
2.4 Penanganan Ketidakseimbangan Kelas.....	4
2.5 Metrik Evaluasi	5
2.6 Referensi Jurnal Pendukung.....	5
BAB III METODOLOGI.....	7
3.1 Mitra dan Sumber Data	7
3.2 Dataset.....	8
3.3 Pelabelan Data.....	10
3.4 Arsitektur Model ANN	10
3.5 Pipeline Pelatihan.....	10
BAB IV HASIL DAN PEMBAHASAN	13
4.1 Deskripsi Dataset	13
4.2 Hasil Pembagian dan Augmentasi Dataset	13
4.3 Hasil Pelatihan Model.....	15

4.4 Hasil Evaluasi Model	16
4.5 Analisis Dashboard Visualisasi.....	18
BAB V_PENUTUP.....	20
5.1 Kesimpulan	20
5.2 Saran.....	20
DAFTAR PUSTAKA	22
LAMPIRAN.....	23
Lampiran 1. Source Code.....	23
Lampiran 2. Dataset	36
Lampiran 3. Dokumentasi Pengambilan Data	37

DAFTAR GAMBAR

Gambar 3. 1 Lokasi Mitra	7
Gambar 4. 1 Dashboard Deteksi Anomali.....	18

DAFTAR TABEL

Tabel 2. 1 Referensi Jurnal Pendukung.....	5
Tabel 3. 1 Profil Mitra.....	7
Tabel 3. 2 Dataset.....	8
Tabel 3. 3 Arsitektur Model ANN	10
Tabel 4. 1 Dataset Final.....	13
Tabel 4. 2 Hasil Pembagian Dataset	14
Tabel 4. 3 Distribusi Data Latih Sesudah SMOTE	14
Tabel 4. 4 Hasil Evaluasi Dataset	16

BAB I

PENDAHULUAN

1.1 Latar Belakang

Liquefied Petroleum Gas (LPG) 3 kg merupakan komoditas bersubsidi yang ditetapkan pemerintah Indonesia sebagai barang penting untuk keperluan rumah tangga tidak mampu, usaha mikro, nelayan, dan petani sasaran. Berdasarkan Keputusan Menteri ESDM No. 37.K/MG.01/MEM.M/2023, distribusi LPG 3 kg hanya diperbolehkan melalui sub-penyialur yang memiliki Nomor Induk Berusaha (NIB) dan hanya kepada pengguna yang telah terdaftar dalam sistem. Sejak 1 Januari 2024, seluruh transaksi pembelian LPG 3 kg diwajibkan dicatat secara digital melalui Merchant Apps Lite (MAP Lite) berbasis NIK-KTP untuk memastikan tepat sasaran [1]. Pangkalan Berlian yang berlokasi di di Jl. Belda Simp. Rahmat No. 76, Banjarmasin, melayani pembelian LPG 3 kg kepada ratusan pembeli setiap bulannya. Pencatatan transaksi saat ini dilakukan secara digital melalui *Merchant Apps Pertamina (mypertamina)*, deteksi dini terhadap perilaku penimbunan masih bergantung pada pengamatan subjektif oleh petugas pangkalan. Kondisi ini mendorong kebutuhan akan sistem berbasis kecerdasan buatan yang mampu mengidentifikasi pola anomali pembelian secara otomatis dan objektif.

Praktik penimbunan LPG 3 kg masih kerap terjadi di tingkat pangkalan meskipun regulasi telah diperketat. Penimbun umumnya adalah pembeli non-UMKM yang secara rutin membeli dalam jumlah maksimum, aktif di semua periode waktu, dan memiliki rasio pembelian yang jauh di atas rata-rata kelompoknya. Perilaku ini merugikan masyarakat yang berhak menerima subsidi dan berdampak langsung pada kelangkaan LPG di tingkat konsumen akhir [2]. Artificial Neural Network (ANN) telah terbukti efektif dalam tugas klasifikasi biner pada data perilaku, termasuk deteksi kecurangan dan anomali pada berbagai domain [3], [4], [5]. Kemampuan ANN dalam mempelajari pola non-linier yang kompleks dari data tabular menjadikannya pilihan yang tepat untuk masalah deteksi anomali pada dataset logbook pangkalan gas. Dengan melatih model ANN menggunakan data historis pembelian yang telah dilabeli, sistem dapat memberikan peringatan dini terhadap pembeli yang menunjukkan indikasi penimbunan.

1.2 Rumusan Masalah

1. Bagaimana membangun model Artificial Neural Network yang mampu mendeteksi anomali perilaku pembelian LPG 3 kg di Pangkalan Berlian?
2. Bagaimana performa model ANN dalam mendeteksi pembeli normal dan pembeli dengan indikasi penimbunan berdasarkan data logbook pangkalan?
3. Fitur apa saja dari data logbook yang paling relevan untuk mengidentifikasi pola penimbunan LPG?

1.3 Tujuan

1. Membangun model ANN berbasis Python (pure NumPy) untuk deteksi anomali perilaku pembelian LPG 3 kg.
2. Mengevaluasi performa model menggunakan metrik Accuracy, Precision, Recall, F1-Score, dan AUC-ROC.
3. Memberikan solusi berbasis machine learning yang dapat digunakan oleh pihak pangkalan sebagai alat bantu pengawasan distribusi LPG.

1.4 Manfaat

Bagi mitra Pangkalan Berlian, implementasi sistem mentransformasi protokol pengawasan distribusi LPG dari pendekatan observasional yang rentan terhadap bias menjadi mekanisme *data-driven decision making*. Automasi deteksi anomali berbasis *Artificial Neural Network* (ANN) secara kalkulatif mereduksi beban kognitif pengelola dalam menganalisis matriks riwayat transaksi yang masif, memitigasi kesalahan manusia (*human error*), serta mengeliminasi subjektivitas penilaian. Hal ini memastikan bahwa intervensi terhadap konsumen yang berindikasi melakukan penimbunan dapat dieksekusi secara instan, objektif, dan presisi di tingkat *last-mile distribution*. Dari perspektif akademik, penelitian ini memformulasi kebaruan (*novelty*) pada literatur sistem deteksi anomali komoditas dengan memvalidasi efikasi arsitektur *Multilayer Perceptron* (MLP) yang dikalibrasi menggunakan algoritma *Synthetic Minority Over-sampling Technique* (SMOTE) pada dataset tabular berskala mikro (*low-resource data*) yang memiliki asimetri kelas ekstrem. Kajian eksperimental ini mengekstrapolasi *baseline* empiris baru bagi komunitas akademik terkait optimalisasi kapabilitas *Machine Learning* dalam memecahkan problematika penyalahgunaan distribusi bahan bakar bersubsidi di negara berkembang.

BAB II

TINJAUAN PUSTAKA

2.1 LPG 3 Kg Bersubsidi dan Permasalahan Distribusinya

LPG 3 kg merupakan komoditas strategis bersubsidi yang diatur oleh Kementerian ESDM Republik Indonesia. Berdasarkan regulasi terbaru (Kepmen ESDM No. 37.K/MG.01/MEM.M/2023), distribusi LPG 3 kg harus dilakukan secara tepat sasaran kepada rumah tangga tidak mampu, usaha mikro, nelayan, dan petani. Realisasi volume LPG 3 kg terus mengalami peningkatan rata-rata 4,5% per tahun, yang sebagian disebabkan oleh perilaku penyalahgunaan seperti penimbunan dan pengoplosan [2]. Untuk tahun 2025, pemerintah mengalokasikan kuota sebesar 8,17 juta metrik ton dengan nilai subsidi mencapai Rp87,6 triliun.

Penimbunan LPG terjadi ketika pembeli membeli dalam jumlah melebihi kebutuhan wajar secara berulang dengan tujuan menjual kembali di atas harga eceran tertinggi (HET). Perilaku ini umumnya ditandai dengan frekuensi pembelian tinggi, selalu membeli kuota maksimum, aktif di seluruh periode bulan, dan rasio pembelian yang signifikan di atas rata-rata kelompok pembeli. Pangkalan sebagai ujung distribusi paling dekat ke konsumen memiliki peran krusial dalam pengawasan fenomena ini.

2.2 Deteksi Anomali dengan Machine Learning

Deteksi anomali adalah proses mengidentifikasi pola atau data yang menyimpang dari perilaku normal dalam suatu dataset [3]. Dalam konteks perilaku pembelian, deteksi anomali dapat diimplementasikan sebagai masalah klasifikasi biner di mana model membedakan antara perilaku normal dan perilaku menyimpang (anomali) berdasarkan fitur-fitur yang diekstrak dari data transaksi. Pendekatan berbasis supervised learning menjadi pilihan ketika tersedia data berlabel hasil anotasi pakar atau aturan domain. Penelitian oleh Nassif et al. (2021) melalui systematic literature review (SLR) terhadap 290 artikel menunjukkan bahwa ANN merupakan salah satu teknik ML yang paling banyak digunakan untuk deteksi anomali di berbagai domain, dengan kemampuan mengklasifikasikan perilaku normal dan anomali secara efektif pada data tabular [3]. ANN mampu mempelajari batas keputusan non-linier yang kompleks antara kelas normal dan

anomali, dan terbukti kompetitif dibandingkan metode tradisional dalam hal akurasi dan efisiensi.

2.3 Artificial Neural Network (ANN)

Artificial Neural Network (ANN) adalah model komputasi yang terinspirasi dari struktur neuron biologis, terdiri dari lapisan input, satu atau lebih lapisan tersembunyi, dan lapisan output [5]. Dalam arsitektur feedforward, sinyal mengalir satu arah dari input ke output melalui proses propagasi maju (forward propagation). Setiap neuron menghitung kombinasi linier dari inputnya kemudian menerapkan fungsi aktivasi non-linier. Fungsi aktivasi Rectified Linear Unit (ReLU) digunakan pada lapisan tersembunyi karena kemampuannya mengatasi vanishing gradient dan mempercepat konvergensi pelatihan. Pada lapisan output, fungsi Sigmoid digunakan untuk menghasilkan probabilitas kelas positif dalam rentang $[0,1]$. Proses pelatihan menggunakan algoritma backpropagation dengan optimisasi mini-batch Stochastic Gradient Descent (SGD), di mana gradien dihitung menggunakan chain rule dan bobot diperbarui secara iteratif untuk meminimalkan fungsi loss Binary Cross-Entropy. Inisialisasi bobot menggunakan metode He Initialization $W \sim N\left(0, \sqrt{\frac{2}{n_{in}}}\right)$ yang direkomendasikan untuk jaringan dengan aktivasi ReLU karena mempertahankan variansi gradien sepanjang lapisan yang dalam [5]. Regularisasi L2 ditambahkan untuk mencegah overfitting dengan memberikan penalti pada bobot yang terlalu besar.

2.4 Penanganan Ketidakseimbangan Kelas

Ketidakseimbangan kelas (class imbalance) merupakan tantangan umum dalam deteksi anomali, di mana jumlah sampel kelas normal jauh lebih banyak dibandingkan kelas anomali. Kondisi ini dapat menyebabkan model cenderung memprediksi semua sampel sebagai kelas mayoritas, menghasilkan akurasi tinggi tetapi recall kelas minoritas yang sangat rendah [6]. Salah satu strategi efektif untuk mengatasi masalah ini adalah class weighting, yaitu memberikan bobot lebih besar pada sampel kelas minoritas dalam perhitungan fungsi loss. Pada penelitian ini, class weighting diterapkan langsung dalam fungsi Binary Cross-Entropy dengan formula $w_c = \frac{n_{total}}{2 n_c}$, sehingga kelas anomali mendapat bobot lebih besar proporsional dengan rasio ketidakseimbangannya. Pendekatan ini efektif tanpa

mengubah distribusi data asli dan terbukti meningkatkan performa recall pada kelas minoritas [6].

2.5 Metrik Evaluasi

Deteksi anomali dengan keadaan data yang tidak seimbang, akurasi saja tidak cukup sebagai metrik evaluasi. Precision mengukur proporsi prediksi positif yang benar-benar positif, sedangkan Recall (Sensitivity) mengukur kemampuan model mendeteksi semua kasus positif yang sesungguhnya. F1-Score merupakan rata-rata harmonik dari Precision dan Recall yang memberikan keseimbangan antara keduanya. AUC-ROC (Area Under the Receiver Operating Characteristic Curve) mengukur kemampuan diskriminasi model secara keseluruhan di berbagai nilai threshold [3], [4]. Optimisasi threshold juga dilakukan untuk menemukan nilai batas keputusan yang menghasilkan F1-Score terbaik pada data validasi, karena threshold default 0.5 tidak selalu optimal pada dataset yang tidak seimbang. Pendekatan ini memungkinkan trade-off antara precision dan recall sesuai kebutuhan domain aplikasi.

2.6 Referensi Jurnal Pendukung

Berikut adalah lima jurnal ilmiah berindeks Scopus yang menjadi rujukan utama penelitian ini.

Tabel 2. 1 Referensi Jurnal Pendukung

No	Judul & Penulis	Nama Jurnal	Tahun / Kuartil	Keterkaitan
1	Kumari et al., "A Comprehensive Investigation of Anomaly Detection Methods in Deep Learning and Machine Learning: 2019–2023"	IET Information Security (Wiley)	2024 / Q2	Survey komprehensif metode deteksi anomali berbasis ANN, termasuk FFNN; landasan teoritis utama penelitian ini

2	Dvilinskas et al., "Enhancing Credit Card Fraud Detection: Highly Imbalanced Data Case"	Journal of Big Data (Springer)	2024 / Q1	Relevan dengan penanganan class imbalance pada deteksi anomali perilaku pembelian menggunakan ANN
3	Nassif et al., "Machine Learning for Anomaly Detection: A Systematic Review"	IEEE Access	2021 / Q1	Systematic review komprehensif metode ML untuk deteksi anomali termasuk ANN; menjadi acuan klasifikasi teknik dan metrik evaluasi yang digunakan dalam penelitian ini
4	Elsayed et al., "Effective Class-Imbalance Learning Based on SMOTE and Convolutional Neural Networks"	Applied Sciences (MDPI)	2023 / Q2	Teknik penanganan imbalanced dataset pada klasifikasi biner menggunakan deep learning; relevan dengan strategi class weighting
5	Zamanzadeh Darban et al., "Deep Learning for Time Series Anomaly Detection: A Survey"	ACM Computing Surveys	2024 / Q1	Taksonomi dan metodologi deteksi anomali berbasis deep learning; dasar pemilihan metrik evaluasi AUC-ROC dan F1-Score

BAB III

METODOLOGI

3.1 Mitra dan Sumber Data

Penelitian ini bermitra dengan Pangkalan Berlian. Pangkalan ini terdaftar dengan Nomor Induk Berusaha (NIB) 070125893942001 dan merupakan sub-penyyalur resmi LPG 3 kg bersubsidi dari agen PT. ABADI GUNUNG RAJA sejak tahun.

Tabel 3. 1 Profil Mitra

Nama Mitra	Pangkalan Berlian
Alamat	Jl. Belda Simp. Rahmat No. 76
Nomor Reg Pangkalan	70125893942001
Agen Penyuplai	PT. ABADI GUNUNG RAJA
Jenis Usaha	Pangkalan LPG 3 kg bersubsidi
Periode Data	Januari – April 2026



Gambar 3. 1 Lokasi Mitra

Data dikumpulkan dari logbook transaksi pembelian LPG 3 kg selama periode Januari hingga April 2026. Dari logbook tersebut, diperoleh data transaksi dari sejumlah pembeli yang kemudian diagregasi per pembeli per periode untuk

menghasilkan fitur-fitur perilaku pembelian. Total dataset yang digunakan setelah proses pembersihan data terdiri dari 214 baris data.

3.2 Dataset

Dataset akhir yang digunakan memiliki dimensi 214 baris dan 24 kolom (23 fitur, 1 label). Distribusi label menunjukkan 169 data Normal (79,0%) dan 45 data Anomali (21,0%). Tabel berikut menjelaskan setiap fitur dalam dataset.

Tabel 3. 2 Dataset

No	Nama Fitur	Deskripsi	Tipe / Nilai
1	bulan_aktif_dari_4	Total bulan pembeli melakukan transaksi dari 4 periode pengamatan	Integer: 1–4
2-5	frekuensi_beli_bln [1-4]	Ekstraksi jumlah transaksi pembelian spesifik pada bulan ke-1 hingga ke-4	Integer
6-9	total_tabung_bln [1-4]	Ekstraksi volume total tabung yang dibeli spesifik pada bulan ke-1 hingga ke-4	Integer
10-13	rasio_vs_rata_kategori_bln [1-4]	Kalkulasi rasio intensitas pembelian terhadap rata-rata kelompok pada bulan ke-1 hingga ke-4	Float
14-16	tidak_aktif_bulan_ini_bln [2-4]	Indikator ketiadaan transaksi (dormansi) pada bulan ke-2 hingga ke-4	Biner: 0/1
17	tren_rasio	Perubahan rata-rata (kemiringan garis tren)	Float

		rasio pembelian selama 4 bulan	
18	std_rasio	Standar deviasi rasio pembelian (mengukur fluktuasi/lonjakan anomali antar bulan)	Float
19	max_rasio	Nilai rasio pembelian tertinggi yang pernah dicapai entitas dalam periode 4 bulan	Float
20	tren_frekuensi	Derajat perubahan tren frekuensi transaksi selama 4 bulan pengamatan	Float
21	total_tabung_4bln	Akumulasi total volume tabung LPG 3 Kg yang dibeli selama 4 bulan (agregat penuh)	Integer
22	n_bulan_maks	Jumlah bulan di mana pembeli membeli hingga batas toleransi kuota maksimum pangkalan	Integer
23	n_bulan_tidak_aktif	Akumulasi jumlah bulan di mana pembeli sama sekali tidak melakukan transaksi	Integer
24	label	Variabel target (<i>ground truth</i>) untuk klasifikasi indikasi penimbunan	Biner: 0 / 1

3.3 Pelabelan Data

Proses pelabelan dilakukan dengan pendekatan berbasis aturan domain (rule-based labeling) berdasarkan masukan dari mitra dan analisis statistik distribusi pembelian. Pembeli dikategorikan sebagai Anomali (label 1) jika memenuhi kombinasi kriteria berikut: frekuensi pembelian tinggi (4 kali dalam 1 bulan), selalu membeli dalam jumlah maksimum, aktif di seluruh periode waktu pembelian, dan memiliki rasio pembelian di atas 1.0 terhadap rata-rata kategorinya. Pembeli yang tidak memenuhi kriteria tersebut dikategorikan sebagai Normal (label 0).

3.4 Arsitektur Model ANN

Model ANN yang dibangun merupakan feedforward neural network murni yang diimplementasikan menggunakan Python dan NumPy tanpa bergantung pada framework deep learning (non-turunan ANN seperti CNN atau RNN). Arsitektur yang dirancang adalah sebagai berikut.

Tabel 3. 3 Arsitektur Model ANN

Layer	Tipe	Neuron	Aktivasi
Input	Input Layer	23	—
Hidden 1	Dense (Fully Connected)	64	ReLU
Hidden 2	Dense (Fully Connected)	32	ReLU
Output	Output Layer	1	Sigmoid

Total parameter model adalah 313 parameter yang dapat dilatih. Konfigurasi hyperparameter yang digunakan solver = 'adam', learning_rate_init=0.001 (Adaptive), dan L2 Regularization alpha = 0.001.

3.5 Pipeline Pelatihan

Proses pelatihan model Artificial Neural Network (ANN) dilakukan melalui serangkaian tahapan sistematis untuk memastikan model dapat belajar secara optimal dan terhindar dari bias serta kebocoran data (data leakage). Tahapan pipeline pelatihan dirancang sebagai berikut.

1. Pembagian Dataset (Data Splitting)

Dataset pivot yang terdiri dari 214 sampel dengan 23 fitur prediktor dibagi menjadi dua, yaitu data latih (training set) dan data uji (testing set). Pembagian dilakukan dengan rasio 80:20 menggunakan teknik Stratified Split untuk memastikan proporsi kelas Normal dan Anomali tetap konsisten di kedua himpunan. Dari proses ini, diperoleh 171 sampel untuk pelatihan dan 43 sampel murni untuk pengujian akhir.

2. Prapemrosesan dan Normalisasi

Sebelum data diolah oleh jaringan saraf tiruan, nilai fitur dinormalisasi agar berada dalam rentang skala yang seragam. Normalisasi dilakukan menggunakan metode Min-Max Scaling yang memetakan seluruh nilai fitur ke dalam rentang $[0, 1]$. Proses fitting (perhitungan nilai minimum dan maksimum) hanya dilakukan pada data latih untuk mencegah data leakage, kemudian parameter yang sama digunakan untuk mentransformasi data uji.

3. Penanganan Ketidakseimbangan Kelas (SMOTE)

Dikarenakan proporsi kelas Anomali (21.0%) jauh lebih sedikit dibandingkan kelas Normal (79.0%), teknik augmentasi Synthetic Minority Over-sampling Technique (SMOTE) diterapkan. SMOTE beroperasi dengan mencari K-Nearest Neighbors ($k=5$) dari sampel kelas minoritas dan menyintesis data baru di sepanjang segmen garis yang menghubungkan tetangga-tetangga tersebut.

Penerapan SMOTE diisolasi secara ketat hanya pada himpunan data latih (setelah proses split). Hal ini menghasilkan penambahan 99 sampel sintetis untuk kelas Anomali, sehingga data latih menjadi seimbang sempurna dengan total 270 sampel (135 Normal dan 135 Anomali). Data uji (43 sampel) dibiarkan pada kondisi aslinya (tidak seimbang) untuk merepresentasikan kondisi riil di pangkalan gas.

4. Pelatihan Arsitektur ANN

Data latih yang telah seimbang dan dinormalisasi kemudian dimasukkan ke dalam model feedforward Multilayer Perceptron (MLP). Model dikonfigurasi menggunakan algoritma optimasi Adaptive Moment Estimation (Adam) dengan learning rate awal sebesar 0.001. Model dilatih

dengan mengoptimalkan fungsi kerugian (loss function) Binary Cross-Entropy.

5. Evaluasi Validasi Silang (10-Fold Cross-Validation)

Untuk memvalidasi ketahanan model dan memastikan hasil yang diperoleh bukan karena kebetulan pada pemisahan data awal, dilakukan 10-Fold Stratified Cross-Validation. Dalam setiap lipatan (fold), dataset dipecah ulang menjadi 90% data latih dan 10% data validasi. Agar evaluasi bersifat imparsial, proses SMOTE diaplikasikan secara independen di dalam setiap iterasi fold hanya pada 90% porsi data latih tersebut, sedangkan 10% data validasi diuji tanpa augmentasi sintetis.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini merupakan hasil ekstraksi dan agregasi (transformasi *pivot*) dari logbook transaksi Pangkalan Berlian selama periode pengamatan Januari hingga April 2026. Berbeda dengan data transaksional mentah yang mencatat per baris transaksi secara sekuensial, dataset ini telah direkayasa menjadi pemprofilan tingkat entitas, di mana satu baris observasi merepresentasikan akumulasi perilaku temporal dari satu pembeli unik secara komprehensif. Transformasi struktural ini secara metodologis diwajibkan untuk memenuhi asumsi *Independent and Identically Distributed* (IID) pada pemodelan *Artificial Neural Network* (ANN). Setelah melalui proses pembersihan data dan eliminasi kolom pengenalan entitas yang tidak memiliki nilai prediktif, seperti *id_pembeli*, *nama_pembeli*, *nik_pembeli*, dan *kategori_pembeli*, dimensi dataset komputasional final terdiri dari 214 baris observasi dan 24 kolom.

Tabel 4. 1 Dataset Final

Kelas	Jumlah Data	Persentase
Normal (0)	169	79,0%
Anomali (1)	45	21,0%
Total	214	100%

Rasio ketidakseimbangan antara kelas Anomali dan kelas Normal berada pada ekuilibrium 1:3,75. Ketimpangan proporsi sebesar 21.0% berbanding 79.0% ini secara literatur diklasifikasikan sebagai *moderate imbalance*. Dalam ruang vektor pembelajaran mesin deterministik, melatih arsitektur ANN menggunakan distribusi probabilitas asli ini akan memicu *majority bias* atau *Accuracy Paradox*, di mana jaringan cenderung mengabaikan pola anomali karena kalah dominan saat kalkulasi gradien fungsi kerugian.

4.2 Hasil Pembagian dan Augmentasi Dataset

Pembagian dataset merupakan tahapan kritis untuk memastikan model dapat dievaluasi pada data yang tidak pernah dilihat sebelumnya. Dataset pivot yang berjumlah 214 observasi dipisahkan menjadi data latih (training set) dan data uji

(testing set) menggunakan rasio 80:20. Proses pemisahan ini dieksekusi secara spesifik menggunakan metode Stratified Split. Penggunaan metode ini menjamin bahwa proporsi kelas Anomali (sekitar 21.0%) dan kelas Normal (sekitar 79.0%) terdistribusi secara identik pada kedua himpunan, sehingga mencegah kegagalan evaluasi akibat absennya kelas minoritas pada data uji.

Tabel 4. 2 Hasil Pembagian Dataset

Subset	Jumlah	Normal	Anomali
Data Latih	171	135	36
Data Uji	43	34	9
Total	214	169	45

Berdasarkan Tabel 4.2, data latih yang digunakan untuk melatih arsitektur Artificial Neural Network (ANN) memiliki ketimpangan yang sangat tinggi di mana 135 berbanding 36. Memasukkan matriks dengan distribusi asimetris ini ke dalam arsitektur ANN akan mengakibatkan majority bias, di mana propagasi gradien (gradient descent) akan lebih memprioritaskan minimalisasi loss pada kelas mayoritas dan mengabaikan kelas minoritas. Oleh karena itu, algoritma Synthetic Minority Over-sampling Technique (SMOTE) diaplikasikan untuk merestorasi ekuilibrium data.

Injeksi SMOTE diisolasi secara mutlak dan hanya diterapkan pada data latih. Data uji sama sekali tidak disintesis untuk memproteksi integritas evaluasi, memastikan bahwa model divalidasi pada distribusi probabilitas alami transaksi di pangkalan gas yang sesungguhnya. Proses komputasi SMOTE menganalisis metrik spasial K-Nearest Neighbors dari 36 sampel anomali asli dan berhasil mengekstrapolasi 99 sampel anomali sintetis tambahan ke dalam ruang fitur data latih. Hasil akhir transformasi dimensi ruang latih dijabarkan pada Tabel 4.3.

Tabel 4. 3 Distribusi Data Latih Sesudah SMOTE

Kelas Klasifikasi	Jumlah Awal	Penambahan Sampel Sintetis	Total Data Latih Akhir
Normal	135	0	135
Anomali	36	+ 99	135
Total X_train	171	+ 99	270

4.3 Hasil Pelatihan Model

Proses pelatihan dilakukan menggunakan pustaka *Machine Learning Scikit-Learn* melalui modul klasifikasi *Multilayer Perceptron* (MLP). Model dibuat dengan matriks data latih yang telah seimbang secara proporsional hasil augmentasi SMOTE berdimensi 270 baris x 23 kolom. Struktur topologi yang dibangun menggunakan arsitektur *feedforward* moderat untuk mencegah jebakan *over-parameterization* yang kerap terjadi saat memodelkan observasi tabular berskala relatif kecil. Rincian spesifikasi arsitektur ANN yang dikompilasi adalah sebagai berikut.

- Lapisan Input (*Input Layer*), mengakomodasi matriks masukan berdimensi 23 fitur numerik spasial.
- Lapisan Tersembunyi 1 (*Hidden Layer 1*), terdiri dari 64 neuron dengan fungsi aktivasi *Rectified Linear Unit* (ReLU). Lapisan ini mengalkulasi 1.536 parameter gabungan (bobot spasial dan bias).
- Lapisan Tersembunyi 2 (*Hidden Layer 2*), terdiri dari 32 neuron dengan fungsi aktivasi ReLU untuk menyaring kompresi fitur non-linier lanjutan, mengalkulasi 2.080 parameter komputasi.
- Lapisan Output (*Output Layer*), terdiri dari 1 neuron terminal menggunakan aktivasi logistik (*Sigmoid*) untuk mengekstrapolasi probabilitas biner dengan rentang kontinuitas 0.0 (Normal) hingga 1.0 (Anomali). Lapisan ini memiliki 33 parameter bobot akhir.

Total parameter keseluruhan yang dioptimasi oleh algoritma komputasi pada model jaringan ini secara absolut berjumlah 3.649 parameter spasial. Fase pembelajaran (*training phase*) dieksekusi menggunakan algoritma optimasi heuristik *Adaptive Moment Estimation* (Adam) dengan nilai inisiasi laju pembelajaran (*learning rate*) adaptif sebesar 0.001. Untuk membatasi fungsi kerugian (*loss function*) agar tidak menghafal *noise* dari titik data sintetis yang dibentuk SMOTE, regularisasi penalti bobot L2 (Ridge Regularization) diimplementasikan pada nilai konstan.

Batas repetisi algoritma (*max_iter*) diatur pada 500 iterasi berdasarkan *log* eksekusi sistem komputasi. Namun, algoritma secara otomatis memotong siklus pembaruan bobot dan mengakhiri pelatihan pada iterasi ke-45. Penghentian dini (*Early Stopping*) ini dipicu oleh kebijakan validasi fraksional (10%) di mana fungsi

toleransi kegagalan mengidentifikasi tidak adanya perbaikan signifikan pada skor akurasi validasi selama 20 iterasi berturut-turut. Terminasi ekuilibrium pada *epoch* ke-45 membuktikan bahwa jaringan telah sukses berkonvergensi secara optimal menuju *local minima* ruang vektor, sekaligus secara absolut menjauhkan model dari jebakan kerusakan *overfitting* yang dapat terjadi jika iterasi dipaksakan berjalan hingga batas akhir.

4.4 Hasil Evaluasi Model

Evaluasi kapabilitas model Artificial Neural Network (ANN) diukur menggunakan dua pendekatan pengujian spasial, yaitu validasi silang pada data latih (10-Fold Cross-Validation) untuk mengukur stabilitas konvergensi dan pengujian deterministik pada data uji murni (Testing Set) sebanyak 43 observasi untuk merepresentasikan keandalan klasifikasi di lingkungan operasional nyata.

1. Evaluasi Validasi Silang (10-Fold Cross-Validation)

Pengujian 10-Fold Stratified Cross Validation yang diintegrasikan dengan SMOTE per lipatan (fold) menghasilkan metrik performa yang sangat stabil. Sembilan dari sepuluh lipatan mencapai akurasi absolut (100.00%), sementara satu lipatan mencetak akurasi 95.24%. Rata-rata akurasi validasi silang adalah 99.52% dengan standar deviasi yang sangat minim, yakni 1.43%. Varians deviasi yang rendah ini secara empiris membuktikan bahwa arsitektur jaringan tidak mengalami fenomena memori residu (*overfitting*) dan memiliki kemampuan generalisasi probabilitas yang konsisten di seluruh distribusi subset pangkalan gas.

2. Evaluasi Himpunan Uji (Testing Set)

Hasil klasifikasi pada himpunan data uji murni mengekstrapolasi matriks metrik evaluasi klasifikasi biner yang dirangkum pada Tabel 4.4 berikut.


Tabel 4. 4 Hasil Evaluasi Dataset

Metrik Evaluasi	Nilai
Accuracy	81.40%
Precision	52.94%
Recall	100.00%
F1-Score	69.23%
AUC-ROC	1.0000

Model Artificial Neural Network (ANN) yang dibangun menunjukkan performa operasional yang sangat sensitif dan tangguh dalam mendeteksi anomali pembelian LPG 3 Kg. Berdasarkan nilai metrik pengujian pada matriks data uji murni, dapat dianalisis bahwa *accuracy* 81,40% menunjukkan model berhasil mengklasifikasikan dengan benar sebesar 35 dari total 43 sampel uji observasi. Recall absolut sebesar 100,00% berarti dari 9 pembeli anomali aktual dalam data uji, model berhasil mendeteksi seluruhnya dengan nol kasus yang tidak terdeteksi (False Negative = 0). Precision 52,94% berarti dari seluruh prediksi yang dituduh model sebagai anomali (17 tebakan), 9 di antaranya adalah penimbun benar. Penurunan presisi ini merupakan penyesuaian logis dari model yang bersifat protektif ekstrem, di mana algoritma menoleransi kesalahan peringatan pada pembeli wajar (False Positive akibat pola transaksi berdekatan). Nilai skalar AUC-ROC 1.0000 mengindikasikan kemampuan diskriminasi probabilitas yang sempurna pada pemisahan batas keputusan non-linier.

Adapun confusion matrix pada evaluasi mengonfirmasi luaran menunjukkan bahwa True Positive (TP) = 9, True Negative (TN) = 26, False Positive (FP) = 8, dan False Negative (FN) = 0. Kelas anomali berhasil dideteksi dengan tingkat recall maksimum ini berkat implementasi augmentasi *Synthetic Minority Over-sampling Technique* (SMOTE) pada data latih yang menyeimbangkan dominasi kelas secara struktural sebelum propagasi matriks, sehingga optimasi fungsi kerugian klasifikasi dapat beroperasi optimal secara absolut tanpa memerlukan manipulasi modifikasi threshold probabilitas statis (0,5).

4.5 Analisis Dashboard Visualisasi



Gambar 4. 1 Dashboard Deteksi Anomali

Visualisasi *dashboard* evaluasi model pada Gambar 4.1 menyajikan tujuh komponen metrik analitik yang membuktikan efektivitas implementasi *Artificial Neural Network* (ANN) dengan augmentasi spasial secara komprehensif. Pertama, grafik Distribusi Kelas mengonfirmasi keberhasilan algoritma SMOTE dalam merestorasi keseimbangan dimensi matriks latih dari kondisi awal yang asimetris menjadi simetris sempurna secara komputasional (menjadi 135 sampel Normal dan 135 sampel Anomali). Kedua, Kurva Loss Training memperlihatkan lintasan fungsi kerugian *Binary Cross-Entropy* yang menurun secara logaritmik dan konvergen dengan mulus, membuktikan bahwa optimasi *Gradient Descent* berhasil menemukan titik minimum tanpa mengalami instabilitas divergensi pada proses propagasi. Ketiga, grafik Confusion Matrix dan pilar Metrik Evaluasi memetakan sensitivitas ekstrem jaringan; visualisasi ini menyoroti keberhasilan sistem mencapai *Recall* 100% (nol *False Negative*), di mana penurunan persentase

Precision (menjadi 52,94%) secara visual terkonfirmasi merupakan hasil dari toleransi sistem yang mencurigai 8 sampel wajar (*False Positive*) demi menjaga tingkat ketetapan deteksi penimbun murni. Selanjutnya, kurva Receiver Operating Characteristic (ROC) mencetak garis probabilitas deterministik bersudut siku sempurna dengan luasan Area Under Curve (AUC) absolut 1,0000. Kesempurnaan diskriminasi linier ini secara empiris divalidasi oleh histogram Distribusi Probabilitas Prediksi, di mana distribusi aktivasi fungsi *Sigmoid* model mampu memisahkan entitas kelas Normal (histogram biru memusat di probabilitas rendah) dan kelas Anomali (histogram merah memusat di probabilitas tinggi) melintasi ambang batas klasifikasi statis 0,5 tanpa tumpang tindih (*overlap*) parsial. Terakhir, grafik 10-Fold Cross Validation mengafirmasi ketahanan generalisasi arsitektur melalui pengujian silang; model secara konsisten mendominasi pengujian lipatan dengan rata-rata akurasi tinggi (99,52%) serta rentang deviasi standar yang sangat sempit (1,43%), mengeliminasi hipotesis kegagalan *overfitting* memori pada himpunan data matriks pangkalan.

BAB V

PENUTUP

5.1 Kesimpulan

Implementasi arsitektur jaringan komputasional cerdas dan analisis metrik klasifikasi terhadap logbook agregat Pangkalan Berlian, penelitian ini menghasilkan kesimpulan bahwa sistem *Artificial Neural Network* (ANN) dengan arsitektur *Multilayer Perceptron* berhasil direkayasa dan dilatih menggunakan optimasi *Adaptive Moment Estimation* (Adam) untuk mendeteksi anomali indikasi penimbunan transaksi pembeli LPG 3 Kg subsidi. Modifikasi struktural agregasi deret waktu menjadi observasi matriks berdimensi [214 x 23] memampatkan relasi temporal menjadi pola statis yang sukses mengoptimasi konvergensi matematis propagasi jaringan secara efisien. Kemudian, pengintegrasian teknik *Synthetic Minority Over-sampling Technique* (SMOTE) secara mutlak menyelesaikan permasalahan bias kelas asimetris. Algoritma SMOTE secara dinamis menginterpolasi ruang minoritas untuk menyintesis 99 entitas anomali baru eksklusif pada iterasi data latih. Isolasi komputasi sintesis di dalam prosedur pelatihan silang memproteksi model dari jebakan *data leakage*, menjamin integritas ekuilibrium pemisahan pada ruang parameter. Evaluasi performa sistem komputasi berhasil mendemonstrasikan keandalan diagnostik tingkat lanjut. Ekstrapolasi 43 observasi data uji murni mencetak tingkat sensitivitas (*Recall*) sempurna 100,00%, mengindikasikan ketiadaan ruang kelemahan (*blind spot*) dengan 0 tingkat *False Negative* pada penangkapan pelaku. Dominasi prioritas keamanan sistem berdampak pada turunnya tingkat parameter presisi menjadi 52,94% namun pertukaran stabilitas komputasi ini (*cost-sensitive equilibrium*) rasional dalam regulasi distribusi agar toleransi mencurigai entitas wajar (8 *False Positive*) dipertahankan guna menjaga rasio probabilitas 100% deteksi kejahatan. Diskriminasi deterministik sistem pada batas keputusan dijamin oleh akurasi silang 99,52% dan nilai kurva aktivasi *AUC-ROC* absolut 1,0000.

5.2 Saran

Penelitian selanjutnya direkomendasikan untuk memperluas komparasi metrik evaluasi dengan membandingkan arsitektur *Artificial Neural Network* (ANN) terhadap algoritma *ensemble learning* berbasis pohon keputusan, seperti *Random*

Forest atau *eXtreme Gradient Boosting* (XGBoost) untuk menetapkan standar dasar (*baseline*) klasifikasi yang lebih holistik. Mengingat efektivitas SMOTE dalam mengatasi ketidakseimbangan kelas pada dataset observasi yang terbatas, eksplorasi metode augmentasi tingkat lanjut seperti *Adaptive Synthetic* (ADASYN) atau *Generative Adversarial Networks* (GANs) sangat disarankan untuk merekonstruksi varians sampel anomali dengan tingkat presisi spasial yang lebih tinggi tanpa memicu bias interpolasi. Dari aspek validitas spasio-temporal, pengumpulan rekam logbook longitudinal yang melampaui empat bulan masa pengamatan wajib diakomodasi untuk menangkap fluktuasi tren musiman yang berpotensi menggeser batas toleransi perilaku pembeli secara dinamis. Secara operasional komersial, luaran komputasi jaringan ini memiliki potensi skalabilitas tinggi untuk dienkapsulasi menjadi Antarmuka Pemrograman Aplikasi (API) dan diintegrasikan secara *real-time* dengan sistem pencatatan digital *Merchant Apps Lite* (MAP Lite) Pertamina; mentransformasi arsitektur pemodelan ini dari sekadar eksperimen analitis menjadi perangkat lunak pengawasan subsidi logistik yang siap beroperasi di tingkat pangkalan.

DAFTAR PUSTAKA

- [1] Kementerian Energi dan Sumber Daya Mineral, “Pendataan Konsumen LPG 3 Kg Fokus Pada Pendistribusian Tepat Sasaran,” ESDM. Accessed: May 31, 2026. [Online]. Available: <https://www.esdm.go.id/id/media-center/arsip-berita/pendataan-konsumen-lpg-3-kg-fokus-pada-pendistribusian-tepat-sasaran>
- [2] Kementerian Energi dan Sumber Daya Mineral, “Subsidi LPG 3 Kg Tepat Sasaran Bermanfaat Bagi Masyarakat Miskin,” Direktorat Jenderal Minyak dan Gas Bumi (MIGAS). Accessed: May 31, 2026. [Online]. Available: <https://migas.esdm.go.id/post/subsidi-lpg-3-kg-tepat-sasaran-bermanfaat-bagi-masyarakat-miskin>
- [3] S. Kumari, C. Prabha, A. Karim, M. M. Hassan, and S. Azam, “A Comprehensive Investigation of Anomaly Detection Methods in Deep Learning and Machine Learning: 2019–2023,” 2024, *John Wiley and Sons Ltd.* doi: 10.1049/2024/8821891.
- [4] A. B. Nassif, M. A. Talib, Q. Nasir, and F. M. Dakalbab, “Machine Learning for Anomaly Detection: A Systematic Review,” 2021, *Institute of Electrical and Electronics Engineers Inc.* doi: 10.1109/ACCESS.2021.3083060.
- [5] J. H. Joloudari, A. Marefat, M. A. Nematollahi, S. S. Oyelere, and S. Hussain, “Effective Class-Imbalance Learning Based on SMOTE and Convolutional Neural Networks,” *Applied Sciences (Switzerland)*, vol. 13, no. 6, Mar. 2023, doi: 10.3390/app13064006.
- [6] D. Breskuvienė and G. Dzemyda, “Enhancing credit card fraud detection: highly imbalanced data case,” *J. Big Data*, vol. 11, no. 1, Dec. 2024, doi: 10.1186/s40537-024-01059-5.
- [7] Z. Zamanzadeh Darban, G. I. Webb, S. Pan, C. Aggarwal, and M. Salehi, “Deep Learning for Time Series Anomaly Detection: A Survey,” *ACM Comput. Surv.*, vol. 57, no. 1, Oct. 2024, doi: 10.1145/3691338.

LAMPIRAN

Lampiran 1. Source Code

```
"""
=====
    DETEKSI ANOMALI PERILAKU PEMBELIAN LPG 3 KG
    ANN + SMOTE (Synthetic Minority Over-sampling Technique)
    Implementasi SMOTE dari scratch – tanpa library eksternal
=====
Dibuat untuk keperluan tugas akhir / penelitian.
Model   : Multilayer Perceptron (MLP) – bukan turunan ANN
Dataset: dataset_lpg_pivot.csv (214 sampel, 23 fitur)
"""

import pandas as pd
import numpy as np
import warnings
warnings.filterwarnings('ignore')

import matplotlib
matplotlib.use('Agg')
import matplotlib.pyplot as plt
import matplotlib.patches as mpatches
import seaborn as sns

from sklearn.neural_network import MLPClassifier
from sklearn.model_selection import train_test_split,
StratifiedKFold
from sklearn.preprocessing import MinMaxScaler
from sklearn.neighbors import NearestNeighbors
from sklearn.metrics import (classification_report,
                             confusion_matrix,
                             roc_auc_score, roc_curve,
                             accuracy_score,
                             precision_score, recall_score,
                             f1_score)
```

```

#
-
# FUNGSI SMOTE (Chawla et al., 2002) – Implementasi Manual
#
-
def smote(X, y, minority_class=1, k=5, random_state=42):
    """
    SMOTE: Synthetic Minority Over-sampling Technique

    Algoritma:
    1. Identifikasi semua sampel kelas minoritas
    2. Untuk tiap sampel minoritas, cari k tetangga terdekat
    (KNN)
    3. Pilih satu tetangga secara acak
    4. Buat sampel sintetis:  $x_{new} = x_i + \alpha \times (x_{nn} - x_i)$ 
       di mana  $\alpha \in [0,1]$  dipilih secara acak (interpolasi)
    5. Ulangi hingga kelas seimbang

    Parameters:
        X            : array fitur (sudah ternormalisasi)
        y            : array label
        minority_class : label kelas minoritas (default 1)
        k            : jumlah tetangga terdekat (default 5)
        random_state  : seed untuk reproduibilitas

    Returns:
        X_resampled, y_resampled, n_synthetic
    """
    rng = np.random.RandomState(random_state)

    X_min = X[y == minority_class] # sampel kelas minoritas
    n_min = len(X_min)
    n_maj = (y != minority_class).sum()
    n_need = n_maj - n_min          # berapa sampel sintetis
    dibutuhkan

    if n_need <= 0:

```

```

        return X, y, 0 # sudah seimbang, tidak
        perlu SMOTE

        # Step 1 - Cari k nearest neighbors untuk setiap sampel
        minoritas

        knn = NearestNeighbors(n_neighbors=k + 1) # +1: sampel
        itu sendiri
        knn.fit(X_min)
        neighbors = knn.kneighbors(X_min,
        return_distance=False)[: , 1:]

        # Step 2 - Buat sampel sintetis
        synthetic = []
        for _ in range(n_need):
            idx = rng.randint(0, n_min) # pilih satu
            sampel acak
            nn_idx = neighbors[idx][rng.randint(0, k)] # pilih
            satu tetangga
            alpha = rng.random() # interpolation
            factor  $\in$  [0,1]
            x_new = X_min[idx] + alpha * (X_min[nn_idx] -
            X_min[idx])
            synthetic.append(x_new)

        X_syn = np.array(synthetic)
        y_syn = np.full(n_need, minority_class)

        X_res = np.vstack([X, X_syn])
        y_res = np.concatenate([y, y_syn])

        return X_res, y_res, n_need

#
-
# 1. LOAD DATASET
#
-

```

```

df = pd.read_csv('dataset_lpg_pivot.csv', sep=';')

print("=" * 65)
print("    DETEKSI ANOMALI LPG 3 KG – ANN + SMOTE")
print("=" * 65)
print(f"\n[DATASET]")
print(f"    Total sampel    : {len(df)}")
print(f"    Jumlah fitur     : {df.shape[1]-1}")
print(f"    Label Normal     (0): {(df['label']==0).sum()} sampel")
print(f"                        {f"({(df['label']==0).mean()*100:.1f}%)"}")
print(f"    Label Anomali    (1): {(df['label']==1).sum()} sampel")
print(f"                        {f"({(df['label']==1).mean()*100:.1f}%)"}")

X = df.drop('label', axis=1).values
y = df['label'].values

#


---


-
# 2. NORMALISASI – Min-Max Scaling ke rentang [0, 1]
#


---


-
scaler = MinMaxScaler()
X_scaled = scaler.fit_transform(X)

#


---


-
# 3. SPLIT DATA – 80% Train / 20% Test (Stratified)
#


---


-
X_train, X_test, y_train, y_test = train_test_split(
    X_scaled, y, test_size=0.2, random_state=42, stratify=y)

print(f"\n[DATA SPLIT]")

```

```

print(f" Training : {len(X_train)} sampel")
print(f" Testing  : {len(X_test)} sampel")

#


---


-
# 4. TERAPKAN SMOTE PADA DATA TRAINING
# PENTING: SMOTE hanya diterapkan pada data training, BUKAN
testing
# Menerapkan SMOTE pada test set akan mencemari evaluasi
(data leakage)
#


---


-
print(f"\n[SMOTE]")
print(f" Sebelum - Normal: {(y_train==0).sum()}, "
      f"Anomali: {(y_train==1).sum()}")

X_train_smote, y_train_smote, n_syn = smote(
    X_train, y_train, minority_class=1, k=5, random_state=42)

print(f" Sesudah - Normal: {(y_train_smote==0).sum()}, "
      f"Anomali: {(y_train_smote==1).sum()} "
      f"({n_syn} sampel sintetis)")
print(f" Total training setelah SMOTE: {len(X_train_smote)}
sampel")

#


---


-
# 5. BANGUN & LATIH MODEL ANN + SMOTE
# Arsitektur: Input(23) → Dense(64,ReLU) → Dense(32,ReLU)
→ Output(Sigmoid)
#


---


-
model = MLPClassifier(
    hidden_layer_sizes=(64, 32),
    activation='relu',

```



```

        solver='adam',
        alpha=0.001,
        learning_rate='adaptive',
        learning_rate_init=0.001,
        max_iter=500,
        early_stopping=True,
        validation_fraction=0.1,
        n_iter_no_change=20,
        random_state=42,
        verbose=False
    )

print(f"\n[TRAINING] Melatih model ANN dengan data SMOTE...")
model.fit(X_train_smote, y_train_smote)
print(f"[TRAINING] Selesai. Total iterasi: {model.n_iter_}")

#


---


-
# 6. EVALUASI MODEL
#


---


-

y_pred = model.predict(X_test)
y_prob = model.predict_proba(X_test)[:, 1]

acc = accuracy_score(y_test, y_pred)
prec = precision_score(y_test, y_pred)
rec = recall_score(y_test, y_pred)
f1 = f1_score(y_test, y_pred)
auc = roc_auc_score(y_test, y_prob)
cm = confusion_matrix(y_test, y_pred)

print("\n" + "=" * 65)
print("    HASIL EVALUASI - ANN + SMOTE")
print("=" * 65)
print(f"    Accuracy      : {acc*100:.2f}%")
print(f"    Precision     : {prec*100:.2f}%")
print(f"    Recall        : {rec*100:.2f}%")

```

```

print(f"  F1-Score      : {f1*100:.2f}%")
print(f"  AUC-ROC        : {auc:.4f}")
print(f"\n  Confusion Matrix:")
print(f"      TN={cm[0][0]}  FP={cm[0][1]}")
print(f"      FN={cm[1][0]}  TP={cm[1][1]}")
print()
print(classification_report(y_test, y_pred,
                             target_names=['Normal (0)', 'Anomali (1)']))

#

```

```

-
# 7. 10-FOLD CROSS VALIDATION
#     SMOTE diterapkan di dalam setiap fold (best practice)
#     agar tidak terjadi data leakage dari fold validasi
#

```

```

-
print("=" * 65)
print("  10-FOLD CROSS VALIDATION (SMOTE per fold)")
print("=" * 65)

cv_scores = []
skf       = StratifiedKFold(n_splits=10,      shuffle=True,
                             random_state=42)

for fold, (train_idx, val_idx) in
enumerate(skf.split(X_scaled, y)):
    Xtr, Xv = X_scaled[train_idx], X_scaled[val_idx]
    ytr, yv = y[train_idx], y[val_idx]

    # SMOTE hanya pada data training tiap fold
    Xtr_s, ytr_s, _ = smote(Xtr, ytr, k=5, random_state=42)

    clf = MLPClassifier(
        hidden_layer_sizes=(64, 32), activation='relu',
solver='adam',
        alpha=0.001, learning_rate='adaptive', max_iter=500,
random_state=42)

```

```

        clf.fit(Xtr_s, ytr_s)

        score = accuracy_score(yv, clf.predict(Xv))
        cv_scores.append(score)
        print(f"  Fold {fold+1:2d}: {score*100:.2f}%")

cv_arr = np.array(cv_scores)
print(f"\n  Mean Accuracy : {cv_arr.mean()*100:.2f}%")
print(f"  Std Deviation : {cv_arr.std()*100:.2f}%")
print("=" * 65)

#


---


-
# 8. PREDIKSI INDIVIDUAL – contoh penggunaan
#


---


-
print("\n[CONTOH PREDIKSI 5 SAMPEL TEST]")
print(f"{'No':>3} | {'Aktual':>7} | {'Prediksi':>9} | {'Prob  
Anomali':>12} | Status")
print("-" * 55)
for i in range(5):
    true = y_test[i]; pred = y_pred[i]; prob = y_prob[i]
    label = "Anomali" if pred == 1 else "Normal "
    status = "✓ Benar" if true == pred else "X Salah"
    print(f"{i+1:>3} | {true:>7} | {label:>9} | {prob:>12.4f}  
| {status}")

print("\n[INFO] Untuk prediksi data baru:")
print("[INFO]  X_new_scaled = scaler.transform(X_new)")
print("[INFO]  pred = model.predict(X_new_scaled)")
print("[INFO]  prob = model.predict_proba(X_new_scaled)[:,  
1]")

#


---


-
# 9. VISUALISASI – Kurva & Grafik Hasil ANN + SMOTE

```

```

#


---


-
print("\n[VISUALISASI] Membuat grafik hasil...")

# Palet warna
C_BLUE   = '#1565C0'
C_RED    = '#C62828'
C_GREEN  = '#2E7D32'
C_ORANGE = '#E65100'
C_PURPLE = '#6A1B9A'
C_TEAL   = '#00695C'
BG        = '#FAFAFA'

fig = plt.figure(figsize=(20, 18), facecolor=BG)
fig.suptitle(
    'Deteksi Anomali Perilaku Pembelian LPG 3 Kg\n'
    'Artificial Neural Network + SMOTE',
    fontsize=17, fontweight='bold', color='#1A237E', y=0.99
)

# — Plot 1: Distribusi Kelas Sebelum & Sesudah SMOTE —————
ax1 = fig.add_subplot(3, 3, 1)
ax1.set_facecolor(BG)
n_before_norm = (y_train == 0).sum()
n_before_anom = (y_train == 1).sum()
n_after_norm  = (y_train_smote == 0).sum()
n_after_anom  = (y_train_smote == 1).sum()

x_pos = np.array([0, 1])
w      = 0.3
b1 = ax1.bar(x_pos - w/2, [n_before_norm, n_before_anom], w,
             color=[C_BLUE, C_RED], label='Sebelum SMOTE',
             edgecolor='white', linewidth=1.5)
b2 = ax1.bar(x_pos + w/2, [n_after_norm, n_after_anom], w,
             color=[C_BLUE, C_GREEN], label='Sesudah SMOTE',
             edgecolor='white', linewidth=1.5, alpha=0.85)
for bar in list(b1) + list(b2):
    ax1.text(bar.get_x() + bar.get_width() / 2,

```

```

        bar.get_height() + 1,
        str(int(bar.get_height()))),
        ha='center', fontweight='bold', fontsize=10)
ax1.set_xticks(x_pos)
ax1.set_xticklabels(['Normal', 'Anomali'], fontsize=10)
ax1.set_title('Distribusi Kelas\nSebelum vs Sesudah SMOTE',
fontweight='bold', fontsize=11)
ax1.set_ylabel('Jumlah Sampel', fontsize=9)
ax1.set_ylim(0, 160)
ax1.legend(fontsize=8)
ax1.grid(axis='y', alpha=0.3)

# — Plot 2: Kurva Loss Training
ax2 = fig.add_subplot(3, 3, 2)
ax2.set_facecolor(BG)
ax2.plot(model.loss_curve_, color=C_BLUE, lw=2.5,
label='Training Loss')
if hasattr(model, 'validation_scores_') and
model.validation_scores_:
    ax2_r = ax2.twinx()
    ax2_r.plot(model.validation_scores_, color=C_ORANGE,
lw=2,
ls='--', label='Val Accuracy')
    ax2_r.set_ylabel('Validation Accuracy', color=C_ORANGE,
fontsize=9)
    ax2_r.tick_params(axis='y', labelcolor=C_ORANGE)
    ax2_r.legend(loc='center right', fontsize=8)
ax2.set_title('Kurva Loss Training\nANN + SMOTE',
fontweight='bold', fontsize=11)
ax2.set_xlabel('Iterasi', fontsize=9)
ax2.set_ylabel('Loss', color=C_BLUE, fontsize=9)
ax2.tick_params(axis='y', labelcolor=C_BLUE)
ax2.legend(loc='upper right', fontsize=8)
ax2.grid(True, alpha=0.3)

# — Plot 3: Confusion Matrix
ax3 = fig.add_subplot(3, 3, 3)

```

```

sns.heatmap(cm, annot=True, fmt='d', cmap='Blues', ax=ax3,
             xticklabels=['Normal', 'Anomali'],
             yticklabels=['Normal', 'Anomali'],
             linewidths=2, linecolor='white',
             annot_kws={'size': 18, 'weight': 'bold'})
ax3.set_title('Confusion Matrix\nANN + SMOTE',
fontweight='bold', fontsize=11)
ax3.set_ylabel('Label Aktual', fontsize=9)
ax3.set_xlabel('Label Prediksi', fontsize=9)

# — Plot 4: ROC Curve


---


ax4 = fig.add_subplot(3, 3, 4)
ax4.set_facecolor(BG)
fpr, tpr, thresholds = roc_curve(y_test, y_prob)
ax4.plot(fpr, tpr, color=C_GREEN, lw=2.5,
         label=f'ANN + SMOTE (AUC = {auc:.4f})')
ax4.plot([0, 1], [0, 1], 'k--', lw=1.2, alpha=0.5,
         label='Random Classifier')
ax4.fill_between(fpr, tpr, alpha=0.1, color=C_GREEN)
ax4.set_title('ROC Curve', fontweight='bold', fontsize=11)
ax4.set_xlabel('False Positive Rate', fontsize=9)
ax4.set_ylabel('True Positive Rate', fontsize=9)
ax4.legend(fontsize=9)
ax4.grid(True, alpha=0.3)

# — Plot 5: Metrik Evaluasi (Bar)


---


ax5 = fig.add_subplot(3, 3, 5)
ax5.set_facecolor(BG)
metric_names = ['Accuracy', 'Precision', 'Recall', 'F1-Score', 'AUC-ROC']
metric_values = [acc, prec, rec, f1, auc]
metric_colors = [C_BLUE, C_PURPLE, C_ORANGE, C_GREEN, C_RED]
bars_m = ax5.bar(metric_names, [v * 100 for v in
metric_values],
                 color=metric_colors, edgecolor='white',
                 linewidth=1.5)
for bar, val in zip(bars_m, metric_values):

```

```

        ax5.text(bar.get_x() + bar.get_width() / 2,
                 bar.get_height() + 0.6,
                 f'{val * 100:.1f}%',
                 ha='center', va='bottom', fontweight='bold',
                 fontsize=10)
ax5.set_ylim(0, 115)
ax5.axhline(80, color='gray', ls=':', lw=1, alpha=0.6)
ax5.set_title('Metrik Evaluasi Model\nANN + SMOTE',
              fontweight='bold', fontsize=11)
ax5.set_ylabel('Nilai (%)', fontsize=9)
ax5.tick_params(axis='x', labelsiz=9)
ax5.grid(axis='y', alpha=0.3)

# — Plot 6: Distribusi Probabilitas Prediksi
_____

ax6 = fig.add_subplot(3, 3, 6)
ax6.set_facecolor(BG)
prob_normal = y_prob[y_test == 0]
prob_anom = y_prob[y_test == 1]
bins = np.linspace(0, 1, 20)
ax6.hist(prob_normal, bins=bins, color=C_BLUE, alpha=0.7,
         label='Normal (Aktual)', edgecolor='white')
ax6.hist(prob_anom, bins=bins, color=C_RED, alpha=0.7,
         label='Anomali (Aktual)', edgecolor='white')
ax6.axvline(0.5, color='black', ls='--', lw=1.5,
         label='Threshold = 0.5')
ax6.set_title('Distribusi Probabilitas Prediksi',
              fontweight='bold', fontsize=11)
ax6.set_xlabel('Probabilitas Anomali', fontsize=9)
ax6.set_ylabel('Frekuensi', fontsize=9)
ax6.legend(fontsize=8)
ax6.grid(True, alpha=0.3)

# — Plot 7: 10-Fold Cross Validation
_____

ax7 = fig.add_subplot(3, 1, 3)
ax7.set_facecolor(BG)
folds = [f'Fold {i+1}' for i in range(len(cv_scores))]
cv_pct = [s * 100 for s in cv_scores]

```

```

bar_cols = [C_TEAL if v >= 99 else C_RED for v in cv_pct]
bars_cv = ax7.bar(folds, cv_pct, color=bar_cols,
                  edgecolor='white', linewidth=1.5, width=0.6)
for bar, val in zip(bars_cv, cv_pct):
    ax7.text(bar.get_x() + bar.get_width() / 2,
             bar.get_height() + 0.2,
             f'{val:.1f}%',
             ha='center', fontsize=9, fontweight='bold')
cv_mean_pct = cv_arr.mean() * 100
cv_std_pct = cv_arr.std() * 100
ax7.axhline(cv_mean_pct, color=C_BLUE, ls='--', lw=2.5)
ax7.fill_between(range(-1, 11),
                 cv_mean_pct - cv_std_pct,
                 cv_mean_pct + cv_std_pct,
                 color=C_BLUE, alpha=0.08)
ax7.set_ylim(85, 105)
ax7.set_xlim(-0.5, 9.5)
ax7.set_title(
    f'10-Fold Cross Validation - ANN + SMOTE\n'
    f'Mean = {cv_mean_pct:.2f}% | Std = {cv_std_pct:.2f}%',
    fontweight='bold', fontsize=12
)
ax7.set_ylabel('Accuracy (%)', fontsize=10)
ax7.grid(axis='y', alpha=0.3)
p1 = mpatches.Patch(color=C_TEAL, label='Accuracy ≥ 99%')
p2 = mpatches.Patch(color=C_RED, label='Accuracy < 99%')
p3 = mpatches.Patch(color=C_BLUE, alpha=0.4,
                    label=f'Mean ± Std ({cv_mean_pct:.2f}% ±
{cv_std_pct:.2f}%)')
ax7.legend(handles=[p1, p2, p3], fontsize=9, loc='lower
right')

plt.tight_layout(rect=[0, 0, 1, 0.97])
output_path = 'ann_smote_kurva_hasil.png'
plt.savefig(output_path, dpi=150, bbox_inches='tight',
facecolor=BG)
plt.close()
print(f"[VISUALISASI] Gambar disimpan → {output_path}")

```


Lampiran 2. Dataset

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X
	bulan_akt	frekuensi	total_tabi	rasio_vs_r	frekuensi	total_tabi	rasio_vs_r	tidak_akt	frekuensi	total_tabi	rasio_vs_r	tidak_akt	frekuensi	total_tabi	rasio_vs_r	tidak_akt	tren_rasio	std_rasio	max_rasio	tren_frekuensi	total_tabi	n_bulan_r	n_bulan_label	X
2	1	1.039	1	1.038	0.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.39	0.192532	0.39	-1	2	2.2	0	0	0	
2	2	2.079	2	2.077	0.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.79	0.390064	0.79	-2	4	2.2	0	0	0	
3	3	3.118	3	3.115	0.0	3	3.097	0.0	3	3.085	0.0	3	3.085	0.0	-0.329999	0.134791	1.18	0	12	4.0	0	0	0	
4	4	8.118	4	8.115	0.0	4	8.109	0.0	4	8.105	0.0	4	8.105	0.0	-0.129999	0.050682	1.18	0	32	4.0	0	0	0	
4	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1	
4	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1	
4	3	3.118	3	3.115	0.0	3	3.097	0.0	3	3.085	0.0	3	3.085	0.0	-0.329999	0.134791	1.18	0	12	4.0	0	0	0	
2	1	1.039	1	1.038	0.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.39	0.192532	0.39	-1	2	2.2	0	0	0	
3	2	2.079	2	2.077	0.0	2	2.064	0.0	0	0.0	1.0	0	0.0	1.0	-0.79	0.322722	0.79	-2	6	3.1	0	0	0	
4	4	8.118	4	8.115	0.0	4	8.109	0.0	4	8.105	0.0	4	8.105	0.0	-0.129999	0.050682	1.18	0	32	4.0	0	0	0	
2	1	1.039	1	1.038	0.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.39	0.192532	0.39	-1	2	2.2	0	0	0	
2	1	1.039	1	1.038	0.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.39	0.192532	0.39	-1	2	2.2	0	0	0	
2	1	1.039	1	1.038	0.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.39	0.192532	0.39	-1	2	2.2	0	0	0	
4	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1	
3	2	2.079	2	2.077	0.0	2	2.064	0.0	0	0.0	1.0	0	0.0	1.0	-0.79	0.322722	0.79	-2	6	3.1	0	0	0	
4	4	8.118	4	8.115	0.0	4	8.109	0.0	4	8.105	0.0	4	8.105	0.0	-0.129999	0.050682	1.18	0	32	4.0	0	0	0	
4	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1	
3	3	3.118	3	3.115	0.0	3	3.097	0.0	0	0.0	1.0	0	0.0	1.0	-1.18	0.483037	1.18	-3	9	3.1	0	0	0	
4	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1	
2	1	1.039	1	1.038	0.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.39	0.192532	0.39	-1	2	2.2	0	0	0	
4	4	4.059	4	8.115	0.0	4	8.109	0.0	4	8.105	0.0	4	8.105	0.0	0.460000	0.222611	1.15	0	28	3.0	0	0	0	
4	3	3.118	3	3.115	0.0	3	3.097	0.0	3	3.085	0.0	3	3.085	0.0	-0.329999	0.134791	1.18	0	12	4.0	0	0	0	
4	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1	
4	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1	
3	3	3.118	3	3.115	0.0	3	3.097	0.0	0	0.0	1.0	0	0.0	1.0	-1.18	0.483037	1.18	-3	9	3.1	0	0	0	
4	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1	
29	4	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1
30	2	2	2.079	2	2.077	0.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.79	0.390064	0.79	-2	4	2.2	0	0	0
31	4	4	8.118	4	8.115	0.0	4	8.109	0.0	4	8.105	0.0	4	8.105	0.0	-0.129999	0.050682	1.18	0	32	4.0	0	0	0
32	2	1	1.039	1	1.038	0.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.39	0.192532	0.39	-1	2	2.2	0	0	0
33	3	2	2.079	2	2.077	0.0	2	2.064	0.0	0	0.0	1.0	0	0.0	1.0	-0.79	0.322722	0.79	-2	6	3.1	0	0	0
34	4	3	3.118	3	3.115	0.0	3	3.097	0.0	3	3.085	0.0	3	3.085	0.0	-0.329999	0.134791	1.18	0	12	4.0	0	0	0
35	4	4	8.118	4	8.115	0.0	4	8.109	0.0	4	8.105	0.0	4	8.105	0.0	-0.129999	0.050682	1.18	0	32	4.0	0	0	0
36	4	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1
37	1	1	1.039	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.39	0.168874	0.39	-1	1	1.3	0	0	0
38	4	8.118	4	8.115	0.0	4	8.109	0.0	4	8.105	0.0	4	8.105	0.0	-0.129999	0.050682	1.18	0	32	4.0	0	0	0	
39	4	3	3.118	3	3.115	0.0	3	3.097	0.0	3	3.085	0.0	3	3.085	0.0	-0.329999	0.134791	1.18	0	12	4.0	0	0	0
40	4	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1
41	4	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1
42	2	1	1.039	1	1.038	0.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.39	0.192532	0.39	-1	2	2.2	0	0	0
43	4	3	3.118	3	3.115	0.0	3	3.097	0.0	3	3.085	0.0	3	3.085	0.0	-0.329999	0.134791	1.18	0	12	4.0	0	0	0
44	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1	
45	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1	
46	3	2	2.079	2	2.077	0.0	2	2.064	0.0	0	0.0	1.0	0	0.0	1.0	-0.79	0.322722	0.79	-2	6	3.1	0	0	0
47	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1	
48	4	8.118	4	8.108	0.0	4	8.082	0.0	4	8.105	0.0	4	8.105	0.0	-0.129999	0.048432	1.18	0	26	3.0	0	0	0	
49	4	4.158	4	4.154	0.0	4	4.129	0.0	4	4.113	0.0	4	4.113	0.0	-0.450000	0.184458	1.58	0	16	4.0	0	1	1	
50	2	2	2.079	2	2.077	0.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.79	0.390064	0.79	-2	4	2.2	0	0	0
51	2	2	2.079	2	2.077	0.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.79	0.390064	0.79	-2	4	2.2	0	0	0
52	2	1	1.039	1	1.038	0.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.39	0.192532	0.39	-1	2	2.2	0	0	0
53	1	1.039	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.39	0.168874	0.39	-1	1	1.3	0	0	0	
54	2	2	2.079	2	2.077	0.0	0	0.0	1.0	0	0.0	1.0	0	0.0	1.0	-0.79	0.390064	0.79	-2	4	2.2	0	0	0
55	4	3	3.118	3	3.115	0.0	3	3.097	0.0	3	3.085	0.0	3	3.085	0.0	-0.329999	0.134791	1.18	0	12	4.0	0	0	0

Lampiran 3. Dokumentasi Pengambilan Data

